

MESOS

数据中心操作系统 的核心

演讲者简介： 俞捷



- **Mesosphere** 技术总监
- **Apache Mesos Committer**, 项目管理委员会委员
- 主要负责容器，网络和存储等项目的研发
- 曾任**Twitter**高级工程师，参与**Mesos**的开发与运维
- **University of Michigan** 计算机科学与工程博士
- 本科毕业于复旦大学

Twitter: @jie_yu

Github: jieyu

演讲简介

- Mesos的起源及架构简介
- 选择Mesos的理由
- Mesos最新功能介绍

Mesos: 数据中心操作系统的内核


- 传统的操作系统内核

- 资源管理： 单机CPU, 内存, 磁盘, ...
- 编程抽象： POSIX API：进程, 线程, ...
- 安全与隔离： 虚拟内存, 用户, ...



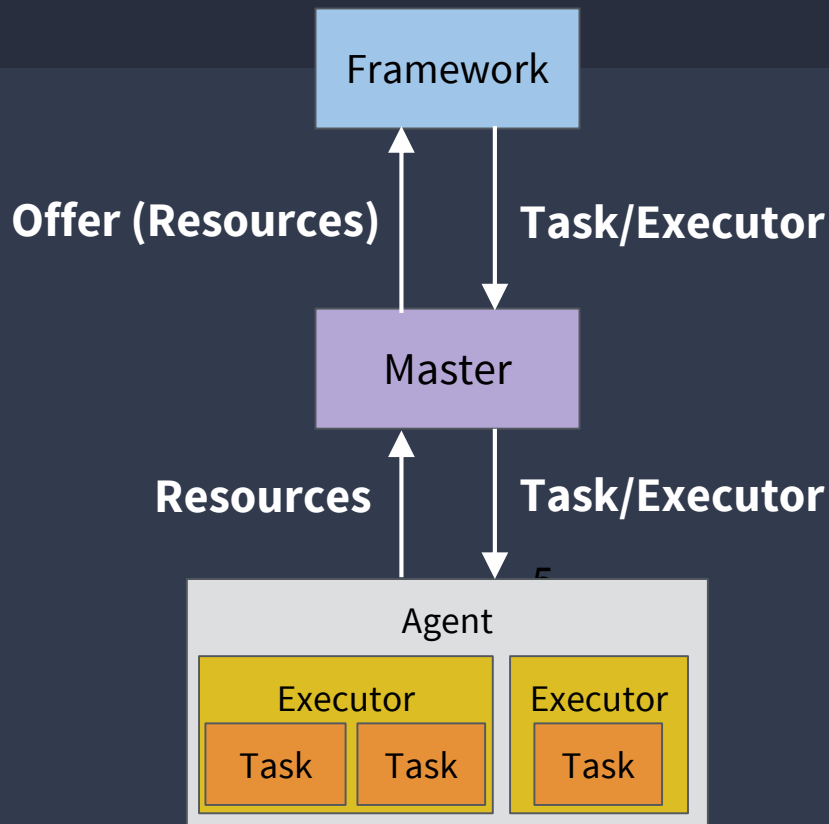
- 数据中心操作系统的内核

- 资源管理： 集群CPU, 内存, 磁盘, ...
- 编程抽象： Mesos API：Resource, ...
- 安全与隔离： 容器化

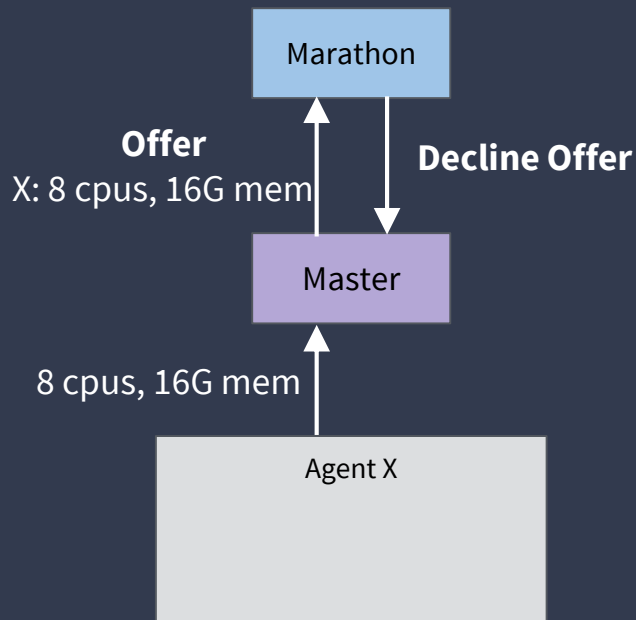


Mesos的编程抽象


- Framework
- Resource/Offer
- Task
- Executor




用例分析: Marathon+Mesos



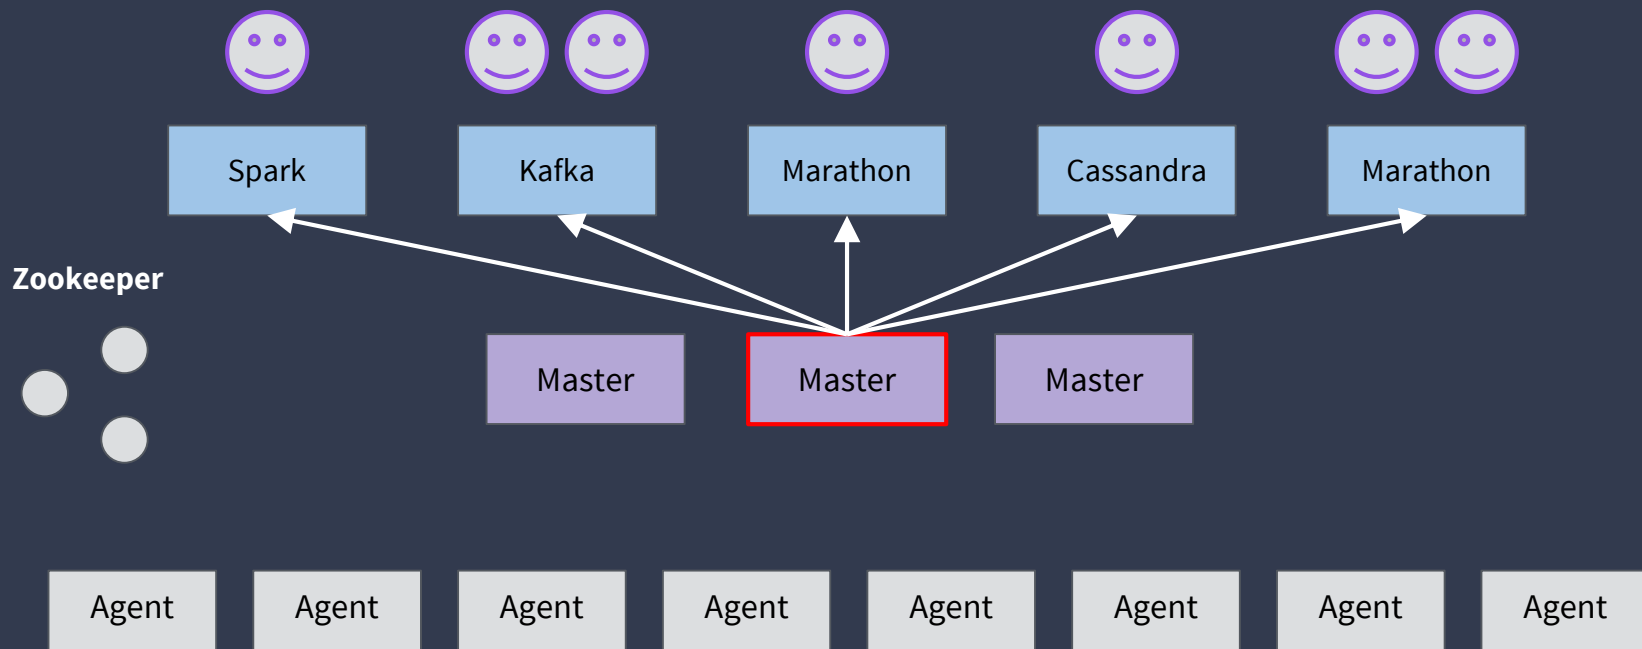
用Marathon启动一个容器





用Marathon启动一个容器



一个典型的Mesos集群架构

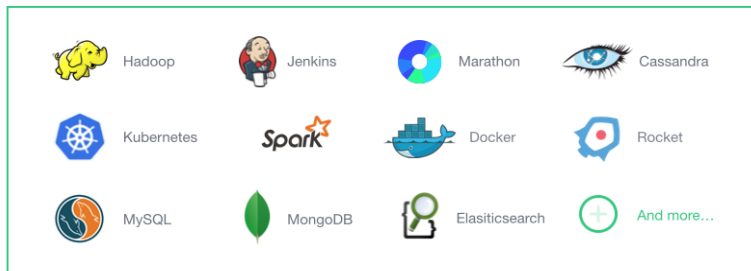


Mesos可以帮助提升集群资源利用效率



Mesosphere DC/OS - Mesos的一个发行版


容器和服务



Mesosphere DC/OS



任意基础架构 公有云 私有云



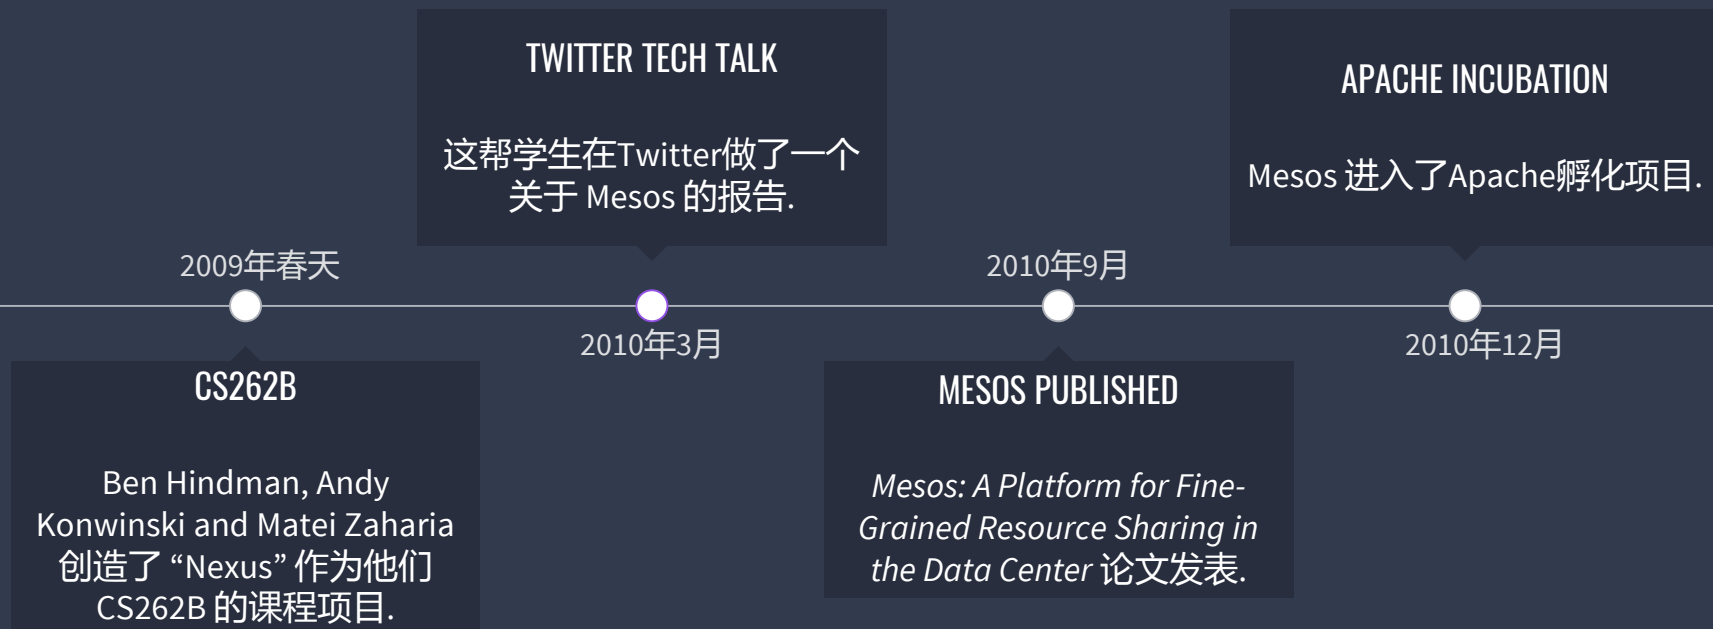
- 只有内核是不够的！
- DC/OS: Mesos最好的发行版
 - 命令行和图形界面
 - 包裹管理
 - 服务发现
 - 负载均衡
 - 调试，日志和监控
 - 用户管理，安全性加强
 - Framework SDK
- 是开源的！

选择Mesos的理由

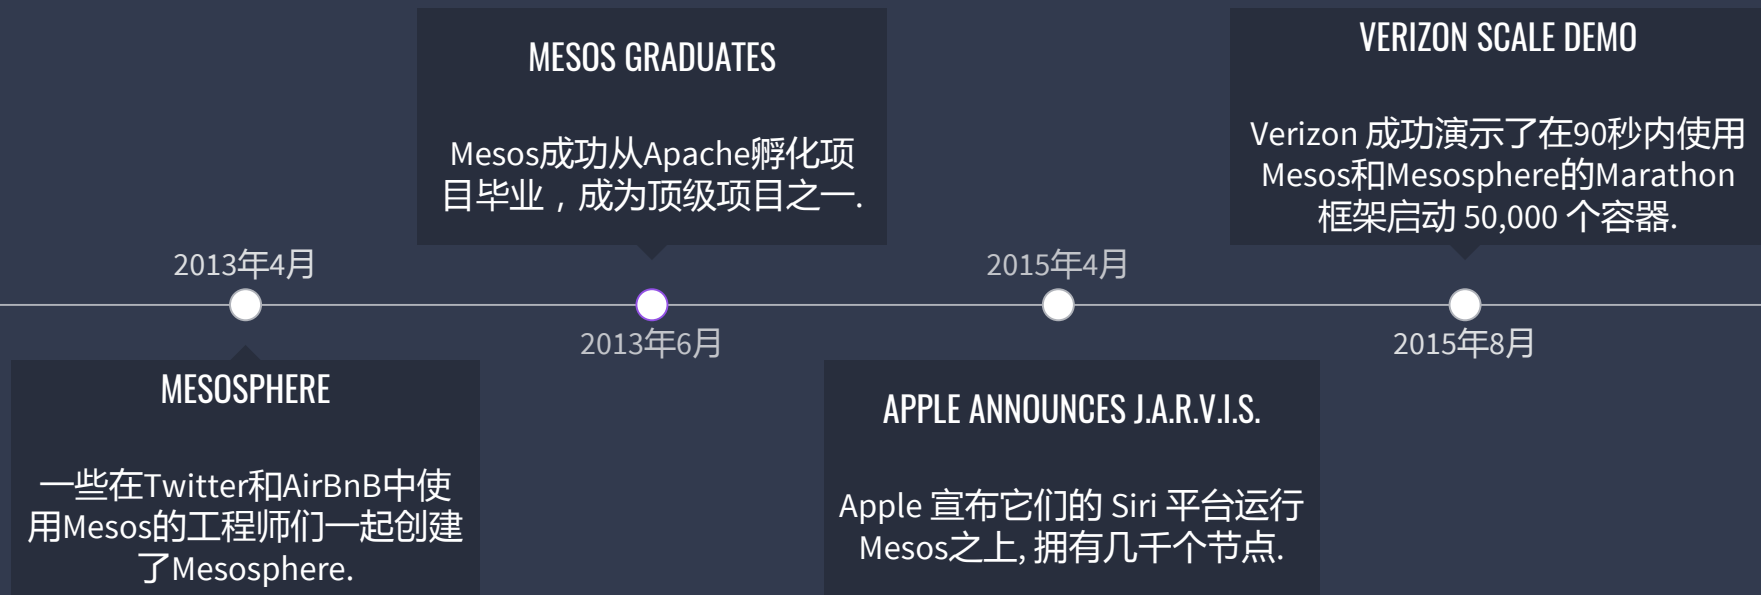
- 在生产环境中被验证过
- 支持超大规模
- 支持模块化自定义和扩展

在生产环境
中被验证过

Mesos的起源：它从生产环境中来



在生产环境中被验证



Mesos的用户



支持超大规模

Twitter

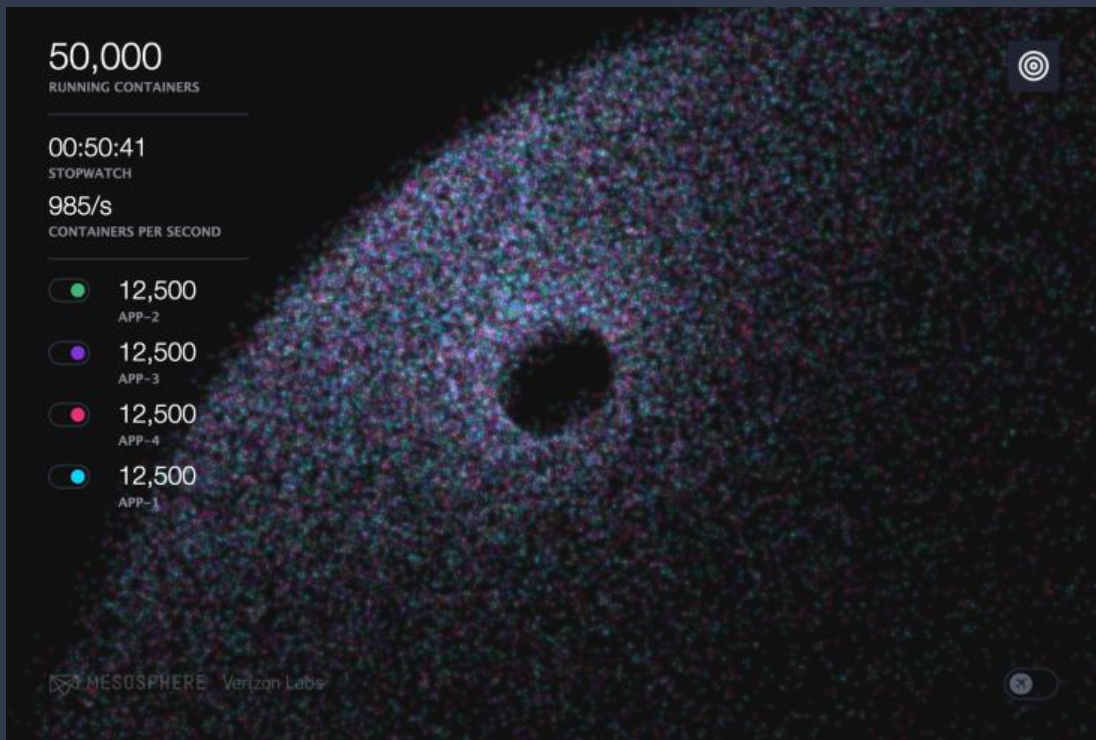


- 多个Mesos集群
- 每个Mesos集群规模
 - > 3万个节点
 - > 25万个容器

Apple



- 整个Siri平台运行在 Mesos



- 50秒完成5万个容器的调度

Mesos为什么能够支撑如此大规模部署

- 无状态的主从Master设计
 - 借鉴GFS(Google Filesystem)的设计理念
 - Agents存储运行任务的状态(分布式)
 - Master的状态可以通过Agent注册重构
- 简单的就是好的，只关心
 - 资源分配和隔离
 - 任务管理
- 用C++写的
 - 没有虚拟机
 - 没有垃圾收集问题

在选型中，这些意味着什么？

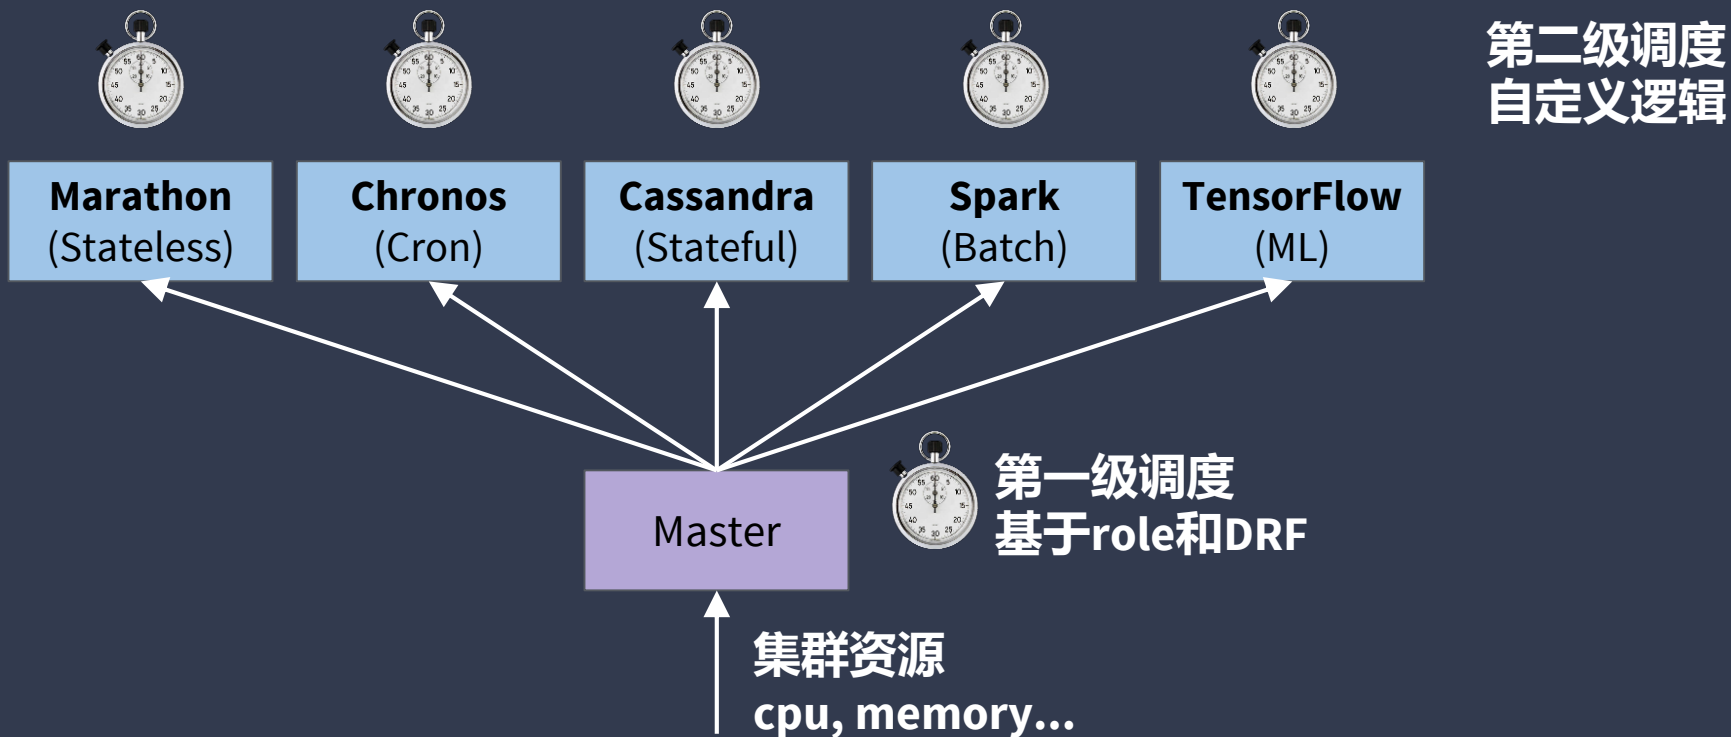
- 知道Mesos可以支持到像Twitter和Apple那样的规模
 - 功能容易添加, 支持大规模并不那么容易
- 免费的软件测试和验证
 - 想象一个有3万节点的真实生产测试环境
- 稳定的接口，对于向后兼容性足够重视
 - We don't want to break their production environment

支持模块化自 定义和扩展

Mesos的理念: 只关注核心抽象

- 其他功能通过模块化扩展，因为每个公司的环境和要求都不同
 - 调度算法
 - 服务发现
 - 容器格式
 - 容器网络
 - 容器存储
 - 特殊硬件和加速器 (e.g., GPU, FPGA)

自定义可扩展的调度 -- Mesos的二级调度



自定义服务发现

- 每个公司的服务发现实现并不相同
 - 基于DNS，用于小规模部署
 - 基于ZK/Etcd/Chubby和统一客户端，用于大规模部署 (Twitter, Google)
 - 自定义的服务发现实现
- Mesos本身不提供服务发现功能，但提供功能支持自定义
 - DiscoveryInfo - 每个任务可以设置一个服务发现的标签
 - Mesos提供接口使得服务发现系统能够获得这些标签

Mesos支持各种容器插件标准

- 容器镜像
 - OCI (Open Container Initiative)
 - Docker
 - Appc
- 容器网络
 - Container Network Interface (CNI)
- 容器存储
 - Docker卷插件 (DVEDI)
 - Container Storage Interface (CSI) (进行时)

容器网络标准: CNI

- Mesos从1.0开始支持 Container Network Interface (CNI)
 - 一个简单，低耦合的容器网络标准
 - 大部分的网络厂商已经支持这个标准



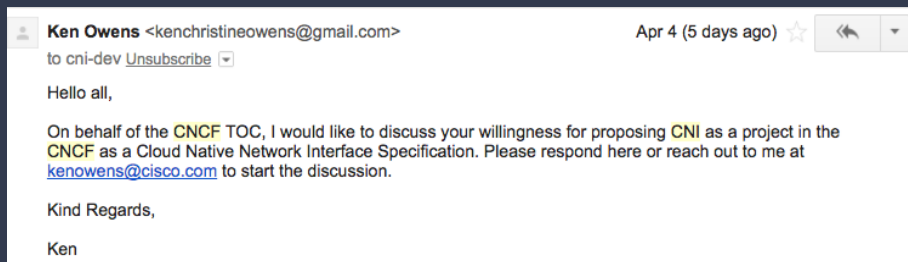
PROJECT
CALICO



weave



- 即将加入CNCF !




容器网络标准: CNI

- 由CoreOS发起

<https://github.com/containernetworking/cni>

- 介于容器管理器和网络插件之间的一个简单的基于JSON的协议
 - 通过命令行的方式调用插件
 - ADD: 加入网络
 - DEL: 退出网络



Mesos为什么选择CNI

- 比Docker CNM (libnetwork)简单且低耦合
- 在其他容器社区也被广泛使用 (e.g., Kubernetes, CF)
- 被主流网络提供商支持
- 在容器和网络管理之间有清晰的界限
- 容器IP地址管理由单独的可扩展接口

容器存储支持

- Mesos从1.0开始支持Docker卷插件
 - Docker卷插件定义了Docker和存储提供商之间的接口
 - https://docs.docker.com/engine/extend/plugins_volume/
- 很多厂商支持这个规范
 - Glusterfs
 - Ceph
 - Convoy
 - Flocker
 - Rexray

一个新的容器存储标准: CSI



CSI: Towards a more universal storage interface for containers

Benjamin Hindman
March 30, 2017

Like 9 Share Tweet in Share 143 Vote 3 G+ 1

Standard interfaces can provide many benefits. For technology vendors, they facilitate collaboration, enable interoperability, and save time and resources from building one-off integrations. For customers, standard interfaces accelerate technology adoption, simplify the user experience, and enable choice. The success of the [Container Networking Interface](#) got us to think: can we do the same for container storage?

<https://mesosphere.com/blog/2017/03/30/csi-towards-universal-storage-interface-for-containers/>

MESOS-7235: Improve Storage Support using Resource Provider and CSI


为什么要推动CSI

- Docker卷插件存在不少设计缺陷
 - 不支持块设备访问
 - 不支持远程分离(detach)
 - Mount/Unmount不是幂等(idempotent)的
- 其他容器存储标准也存在不少问题
 - Kubernetes Flex Volume
 - Libstorage
- 并没有一个现有标准能够解决大部分问题

容器镜像支持

- Mesos支持多种容器镜像格式，且可方便扩展
 - Docker
 - Appc
 - OCI (正在开发)
 - [CVMFS](#) (实验性)
 - 宿主机文件系统 + tar/jar包

容器管理接口(Containerizer)



Containerizer

介于Agent和容器之间的组件

启动更新销毁容器

负责容器之间的隔离

汇报容器状态和信息

目前支持的容器管理器

- DockerContainerizer
 - 利用Docker daemon
 - 将来可能会利用containerd

可以同时使用！！！！

- MesosContainerizer
 - 使用标准OS特性 (e.g., cgroups, namespaces)
 - 模块化设计，支持自定义和扩展

Mesos最新功能介绍


Mesos最新功能介绍

- 原生Docker镜像支持
- Nvidia GPU支持
- 多容器统一调度(Pod)的支持
- 远程容器调试支持
- 支持网络阻隔时的多种策略
- 多个role和阶级式role的支持

Nvidia GPU支持

Nvidia-docker


Nvidia开发的一个工具
使得开发人员能够更容易的在Docker容器里面
使用GPU



Source: <https://devblogs.nvidia.com/parallelforall/nvidia-docker-gpu-server-application-deployment-made-easy/>

Nvidia GPU支持


本地开发 nvidia-docker



生产环境部署 Mesos



nvidia-docker到底做了些什么



它在Docker客户端上包了一层

寻找Docker镜像是否有一下这个标签

```
com.nvidia.volumes.needed = nvidia_driver
```

如果有，就自动把nvidia的基础库(nvidia_XXX.XX)
通过卷的方式加载到容器里面

```
/usr/local/nvidia
```

Mesos的GPU支持

- 模拟了nvidia-docker的功能
 - 支持docker容器的nvidia标签
 - 挂载nvidia基础库到容器内的 /usr/local/nvidia
 - 自动发现宿主机上的GPU，并且注入到容器之中
- 容器之间GPU设备的隔离
 - 只使用nvidia-docker的话无法达到
- 和Mesos的资源管理完美结合
 - GPU和CPU一样，是一种资源

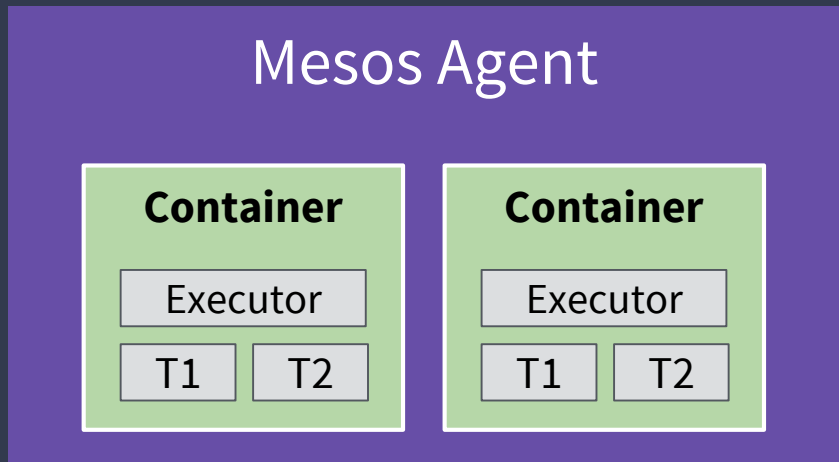
多容器统一调度(Pod)的支持

Frameworks启动Tasks

- Tasks指定executor

Executors运行tasks

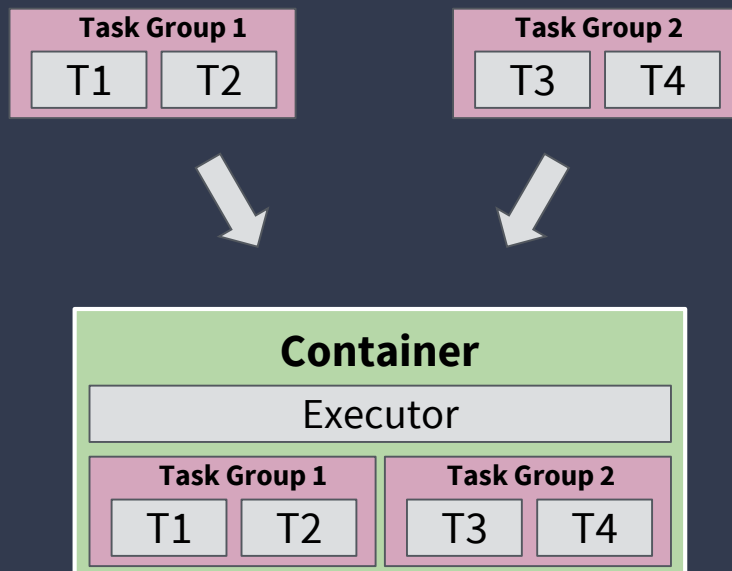
- 每个executor可以有多个tasks
- 每个executor是一个容器



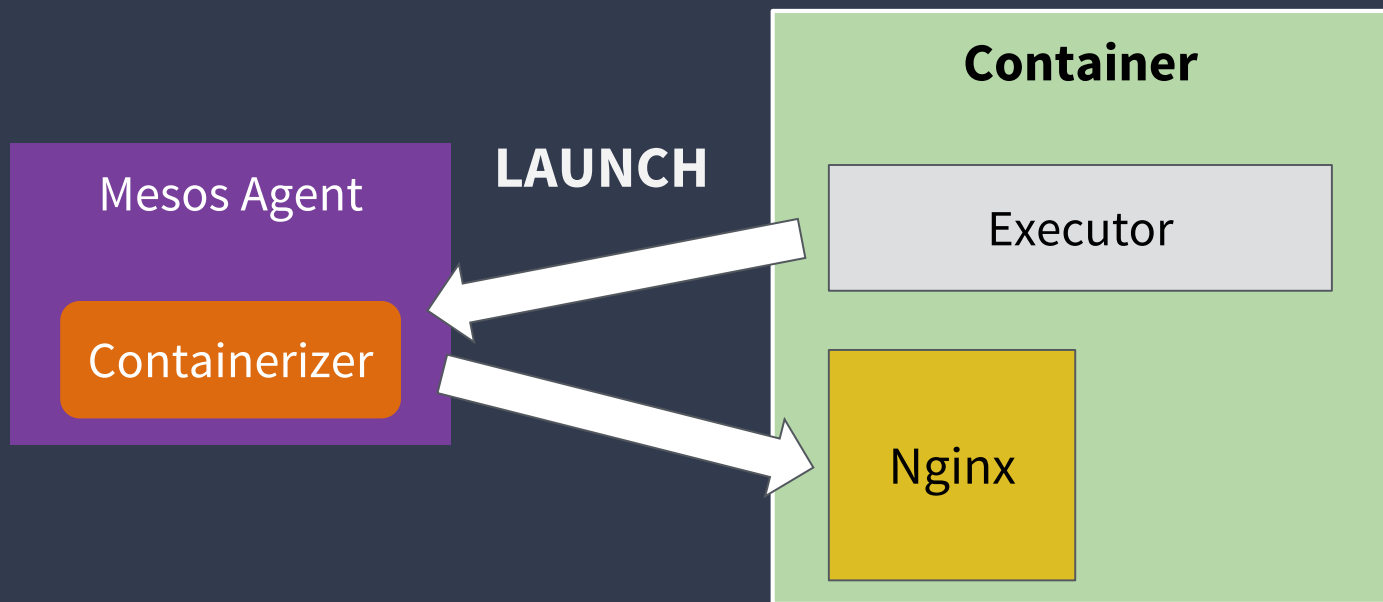
新增的功能 #1: 任务组(Task Group)

Framework现在可以启动一组tasks (TaskGroup)


Executor可以原子性地 (atomically) 收到TaskGroup



新增的功能 #2: 容器嵌套(Nested Container)



支持任意层数的嵌套



多个role和阶级式role的支持

Mesos是一个资源管理系统

- 在用户之间提供资源的共享
- 给某些用户提供最低资源保障
- 提供资源统计
 - 有多少资源已经被分配了，多少被利用了？
 - 每个用户有资源统计

多个role和阶级式role的支持

Mesos是一个资源管理系统

- 在用户**role**之间提供资源的共享
- 给某些用户**role**提供最低资源保障
- 提供资源统计
 - 有多少资源已经被分配了，多少被利用了？
 - 每个用户**role**有资源统计

“Role”：资源消费者

(e.g. 用户, 单位, 服务账号, etc).

基于Role的资源分配



28 CPUs
56GB mem
100GB disk

14 CPUs
28GB mem
50GB disk

14 CPUs
48GB mem
800GB disk

72 CPUs
128GB mem
100GB disk

“frontend”


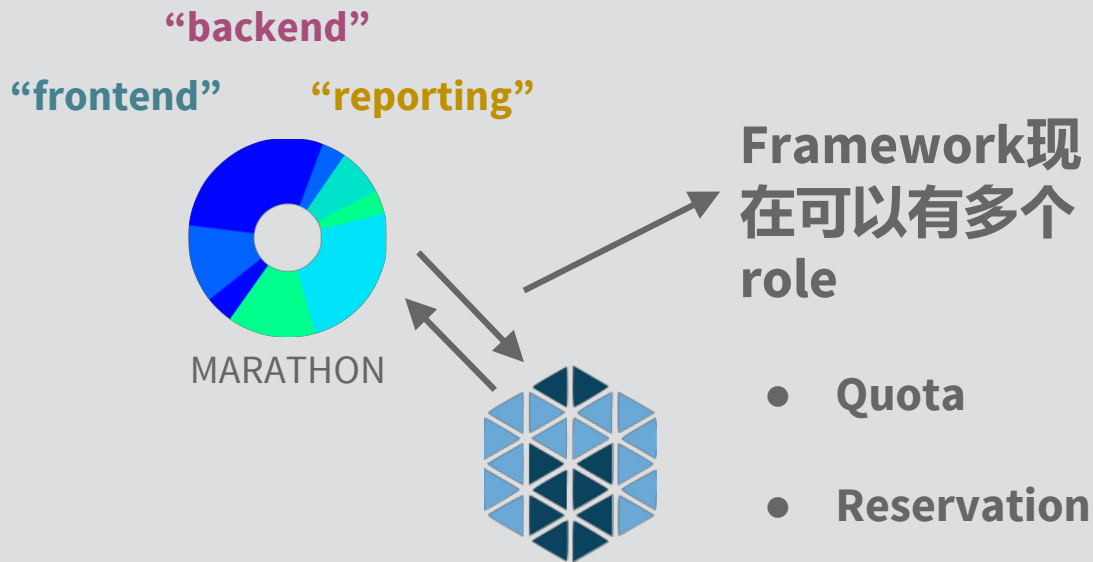
“backend”

“storage”

“analytics”




Framework 可以支持 多个role



阶梯式role的支持

阶梯式role的支持，大部分组织结构都是阶梯式的：

- `engineering/frontend/ui`
- `engineering/backend/api`



总结

Mesos是一个很强大且稳定的数据
中心操作系统内核

在生产环境中被验证过
支持超大规模
支持模块化自定义和扩展

最近在保持稳定性的同时又加入
了很多新功能

